

รายงาน

การเปรียบเทียบอิทธิพลของ Shape และ Texture ในโมเดล CNN: กรณีศึกษา Cue Conflict)

โดย

นายอนัสพงษ์ ลือไชย รหัสนักศึกษา 670610827

คำถาม: โมเดล ResNet18 อาศัยข้อมูลจากรูปร่างภายนอก (Global Shape) หรือ พื้นผิว(Texture) มากกว่ากันในการจำแนกภาพสัตว์?

คำทำนาย: คาดเดาว่าโมเดล Baseline ที่สอนด้วยภาพสัตว์ปกติ จะอาศัยข้อมูลจาก พื้นผิว (Texture Bias) มากกว่า เพราะว่าตัว CNN มักสกัดคุณลักษณะจากระดับพิกเซล ย่อย ดังนั้นเมื่อนำภาพที่ขัดแย้ง เช่น รูปแมวที่มีขนเป็นเกล็ดงู สุนัขที่มีขนเป็นลวดลาย ของม้าลาย มาทดสอบโมเดล Baseline น่าจะถูกกลบกลืนพื้นผิวที่เปลี่ยนไปหลอกและ ทำนายผิด ในทางกลับกัน คาดเดาว่า โมเดล Shape-biased ที่ถูกฝึกด้วยภาพที่มีแต่เส้น ขอบ จะสามารถตอบคำถามได้ถูกต้อง เพราะว่าได้มองข้ามเรื่องลวดลายและมองแค่ ลักษณะเส้นรอบๆเท่านั้น

วิธีการทดลอง (Methodology)

การทดลองนี้ถูกออกแบบมาเพื่อเปรียบเทียบพฤติกรรมการตัดสินใจของโมเดล CNN เมื่อได้รับข้อมูลภาพที่มีลักษณะขัดแย้งกัน (Cue Conflict) โดยแบ่งขั้นตอนการดำเนินงานออกเป็น 3 ส่วนหลัก ดังนี้:

1. การเตรียมชุดข้อมูลและการประมวลผลภาพเบื้องต้น

ชุดข้อมูลที่ใช้ในการทดลองคือ Cats vs Dogs นี่คือ Link:

<https://www.kaggle.com/datasets/marquis03/cats-and-dogs/code>

License (สัญญาอนุญาต): Apache 2.0

ซึ่งประกอบด้วยภาพสัตว์ 2 คลาส ได้แก่ แมว และสุนัข ผู้วิจัยได้แบ่งการเตรียมข้อมูลออกเป็น 2 รูปแบบเพื่อใช้สำหรับฝึกสอนโมเดล 2 ตัวที่ต่างกัน:

ชุดข้อมูลอ้างอิง (Baseline Dataset): ใช้ภาพสี RGB สภาพปกติจากชุดข้อมูลโดยตรง ซึ่งประกอบไปด้วยข้อมูลทั้งด้านรูปร่าง (Shape) และพื้นผิว/ลวดลาย (Texture) โดยนำมาปรับขนาดเป็น 224x224 พิกเซล และทำ Normalization ตามมาตรฐานของ ImageNet

ชุดข้อมูลสกัดเส้นขอบ (Shape-only Dataset): นำภาพจากชุดข้อมูลเดิมมาประมวลผลผ่านไลบรารี OpenCV เพื่อลบข้อมูลสีและลวดลายออกให้เหลือเพียงโครงร่าง โดยแปลงเป็นภาพระดับสีเทา (Grayscale) ลดสัญญาณรบกวนด้วย Gaussian Blur และสกัดเส้นขอบด้วยอัลกอริทึม Canny Edge Detection เพื่อบังคับให้ภาพเหลือเพียงคุณลักษณะด้านรูปร่าง (Global Shape)

2. สถาปัตยกรรมโมเดลและการควบคุมตัวแปร (Model Architecture & Reproducibility)

สถาปัตยกรรม: เลือกใช้โมเดล ResNet18 (Pre-trained) โดยนำมาทำ Fine-tuning ผ่านการปรับโครงสร้าง Fully Connected Layer (fc) ชั้นสุดท้ายให้สอดคล้องกับจำนวนคลาสที่ต้องการทำนาย (สุนัขและแมว)

การควบคุมการจำลอง: เพื่อให้ผลการทดลองมีความแม่นยำและสามารถทำซ้ำได้ (Reproducible) จึงมีการกำหนดค่า Seed (Set Seed) เพื่อลดความสุ่มของการจัดเรียงข้อมูล (Data Shuffling) และการสุ่มค่าน้ำหนักเริ่มต้น (Weight Initialization) ในทุกกระบวนการของระบบ

3. การฝึกสอนโมเดล (Training Process)

ทำการฝึกสอนโมเดล 2 ตัวแยกกัน ได้แก่ Baseline Model (เรียนรู้จากภาพสี) และ Shape-biased Model (เรียนรู้จากเส้นขอบ) โดยกำหนด Hyperparameters ให้เหมือนกันเพื่อควบคุมตัวแปรอิสระ ดังนี้:

Loss Function: Cross-Entropy Loss

Optimizer: Adam (Learning Rate = 0.001)

จำนวนรอบการฝึก (Epochs): 5 รอบ

4. การทดสอบสมมติฐานด้วยภาพความขัดแย้ง (Cue Conflict Testing)

หลังจากฝึกสอนสำเร็จ นำโมเดลทั้ง 2 ตัวเข้าสู่โหมดประเมินผล (Evaluation Mode) และทดสอบด้วยภาพ "Cue Conflict" ซึ่งเป็นภาพที่มีคุณลักษณะขัดแย้งกันในตัว (ตัวอย่างเช่น ภาพโครงร่างของแมวที่ถูกซ้อนทับด้วยลวดลายของม้าลาย) เพื่อวิเคราะห์ผลลัพธ์ผ่านค่าความมั่นใจ (Confidence Score/Softmax) ว่าโมเดลแต่ละเงื่อนไขใช้สิ่งใดเป็นปัจจัยหลักในการตัดสินใจระหว่าง Shape หรือ Texture

ผลการทดลอง (Results)

1. ประสิทธิภาพของโมเดลหลังการฝึกสอน (Training Accuracy)

ก่อนทำการทดสอบสมมติฐาน ผู้วิจัยได้ประเมินความสามารถพื้นฐานของโมเดลบนชุดข้อมูลปกติ เพื่อยืนยันว่าโมเดลมีประสิทธิภาพเพียงพอและไม่ได้ตัดสินใจจากการสุ่มเดา:

Baseline Model (ฝึกด้วยภาพสีปกติ):

ได้ค่าความแม่นยำ (Accuracy) และค่าความผิดพลาด (Loss) ดังนี้

...	เริ่มกระบวนการฝึกสอน (Training)...
Epoch 1/5	
Loss: 0.6563	Accuracy: 0.7927
Epoch 2/5	
Loss: 0.5028	Accuracy: 0.7455
Epoch 3/5	
Loss: 0.2922	Accuracy: 0.8727
Epoch 4/5	
Loss: 0.2964	Accuracy: 0.8727
Epoch 5/5	
Loss: 0.1943	Accuracy: 0.9236
เทรนเสร็จสิ้นในเวลา 0 นาที 10 วินาที	

Shape-biased Model (ฝึกด้วยภาพสกัดเส้นขอบ):

ได้ค่าความแม่นยำ (Accuracy) และค่าความผิดพลาด (Loss) ดังนี้

...	เริ่มกระบวนการฝึกสอน (Training)...
Epoch 1/5	
Loss: 0.9002	Accuracy: 0.6655
Epoch 2/5	
Loss: 0.5126	Accuracy: 0.7527
Epoch 3/5	
Loss: 0.2840	Accuracy: 0.8909
Epoch 4/5	
Loss: 0.2198	Accuracy: 0.9127
Epoch 5/5	
Loss: 0.3474	Accuracy: 0.8545
เทรนเสร็จสิ้นในเวลา 0 นาที 10 วินาที	

2. ผลการทดสอบด้วยภาพความขัดแย้ง (Cue Conflict Testing)

ได้นำภาพทดสอบจำลองที่มีคุณลักษณะขัดแย้งกัน (โครงร่างเป็นแมว แต่มีพื้นผิวเป็นลวดลายม้าลาย) ป้อนเข้าสู่โมเดลทั้งสองเพื่อประเมินความเอนเอียง (Bias) ในการตัดสินใจ ผลลัพธ์ปรากฏดังตารางต่อไปนี้:



รูปภาพแมวที่มีลายแบบม้าลาย

Model	ข้อมูลที่ใช้ฝึก	ผลการทำนาย	Confidence	ปัจจัยหลักที่โมเดลใช้ตัดสินใจ
Baseline Model	ภาพสุนัขกับแมว (มีรูปร่าง+พื้นผิว)	class_1 แมว (ลวดลายม้าลาย)	71.78%	พื้นผิวและลวดลาย
Shape-Biased Model	ภาพลายเส้นของภาพหมากับแมว Canny Edge	class_2 สุนัข (โครงร่างแมว)	81.37%	รูปร่างภายนอก

การตีความ (Interpretation)

ผลการทดสอบให้ผลลัพธ์ที่น่าสนใจและขัดแย้งกับคำทำนายเบื้องต้น โดยสามารถตีความพฤติกรรมของโมเดลได้ดังนี้:

Baseline Model ทำนายว่าเป็น "แมว" (71.78%): เนื่องจากไม่มีคลาสม้าลายให้เลือก โมเดลจึงต้องตัดสินใจจากรูปร่างภายนอกแทน อย่างไรก็ตาม ลวดลายแปลกปลอมทำให้โมเดลเกิดความสับสน ส่งผลให้ความมั่นใจลดลง

Shape-Biased Model ทำนายว่าเป็น "สุนัข" (81.37%): สีขาว-ดำที่ตัดกันของลวดลายม้าลาย ทำให้กระบวนการ Canny Edge สกัดเส้นขอบยิบย่อยออกมามากเกินไปจนบดบังโครงร่างจริงของแมว โมเดลจึงตีความกลุ่มเส้นขอบที่ยุ่งเหยิงนั้นผิดพลาดว่าเป็นขนของสุนัขแทน

ข้อจำกัดของการทดลอง (Limitations)

ข้อจำกัดของกระบวนการสร้าง Shape-biased Dataset: การใช้ Canny Edge Detection เพื่อลบข้อมูล Texture ออกจากภาพ ยังไม่ใช่วิธีที่สมบูรณ์แบบ หากรูปภาพต้นฉบับมีลวดลายที่มีความเปรียบต่างสูง (High Contrast) เช่น ลายผ้าลาย หรือลายจุด อัลกอริทึมจะสกัดลวดลายนั้นออกมาเป็นเส้นขอบ (Edges) ด้วย ทำให้เส้นขอบภายในไปกวนการเรียนรู้รูปร่างรอบนอก (Global Shape) ของโมเดล

จำนวนคลาสในการทดสอบจำกัด: การทดสอบความขัดแย้ง (Cue Conflict) ระหว่างแนวและผ้าลาย บนโมเดลที่รู้จักแค่แนวและสุนัข ทำให้เราไม่สามารถวัดได้อย่างชัดเจนว่า Baseline Model ต้องการเลือกผ้าลาย (Texture) หรือไม่ เพราะโมเดลถูกบังคับให้ต้องเลือกคลาสที่มีอยู่เท่านั้น

การใช้ AI ในการทำ

ในการจัดทำโครงงานและรายงานฉบับนี้ ผู้จัดทำได้ใช้ AI (Gemini) เป็นผู้ช่วยในหลายขั้นตอน โดยมีรายละเอียดการใช้งาน ประโยชน์ที่ได้รับ และข้อผิดพลาดที่พบ ดังนี้:

1. ส่วนที่ใช้ AI ช่วยเหลือและเป็นประโยชน์ (What worked well)

1.1 การเขียนโค้ดและแก้ไขข้อผิดพลาด (Coding & Debugging): ใช้ AI ช่วยร่างโครงสร้างโค้ด PyTorch สำหรับการเทรนโมเดล ResNet18 และช่วยเขียนฟังก์ชัน `set_seed()` เพื่อควบคุมตัวแปรสุ่มให้ผลการทดลองสามารถทำซ้ำได้ (Reproducible)

1.2 การเรียบเรียงภาษาในรายงาน: ใช้ AI ช่วยเกลารายงานในส่วน "วิธีการทดลอง" และ "ผลการทดลอง" ให้มีความเป็นวิชาการและอ่านเข้าใจง่ายขึ้น

2. ส่วนที่ AI พาหลงทางหรือให้ข้อมูลคลาดเคลื่อน

2.1 การจัดการชุดข้อมูล: AI ให้คำแนะนำเบื้องต้นเกี่ยวกับการแตกไฟล์และโหลดชุดข้อมูลที่เรียบง่ายเกินไป โดยไม่ได้เตือนแต่แรกว่าชุดข้อมูล Kaggle Cats and Dogs มักมีไฟล์รูปภาพที่เสียหาย และไฟล์ขยะแฝงอยู่ ทำให้โค้ดพังระหว่างการเทรน

2.2 ในส่วนของภาระระดมความคิด AI เข้าใจจุดประสงค์ในการทำรายงานชิ้นนี้ขึ้นมาพลาดบ้าง และด่วนตัดสินใจผลการทดลองทุกครั้งที่สอบถามกระบวนการการรันโค้ด ทำให้เกิดข้อผิดพลาดบ่อยและใช้เวลาในการแก้ไขทีนาน